

研究内容注意事项:

一、研究内容

- (1)研究内容（凝练 2-3 条，简要说明解决的问题，每条里面包括 2-3 个小部分，详细说明 200 字）
- (2)研究目标（要完成的具体任务，产出什么结果）
- (3)解决的问题（解决的具体科学问题，问题要具体，不宜过大）
- (4)研究方法（包括数据集、详细写使用的具体方法——注意力、多尺度等）
- (5)技术路线（总体汇总成流程关系图）

开题报告

一、研究内容：毕业论文的研究内容、研究目标，拟解决的关键科学问题

1.1 研究内容

本项目重点涉及两个方面的研究内容：面向高分辨率遥感影像分析的模型压缩算法和轻量化注意力模型，通过对主流的模型压缩算法在遥感影像分析任务应用的研究，重点解决卷积神经网络中注意力模块计算量大和内存消耗大、模型参数冗余度高的问题；通过设计轻量型卷积算子和改进训练方法，重点解决资源受限下的遥感影像的语义分割和变化检测精度。各研究内容之间的关系如图 1 所示。

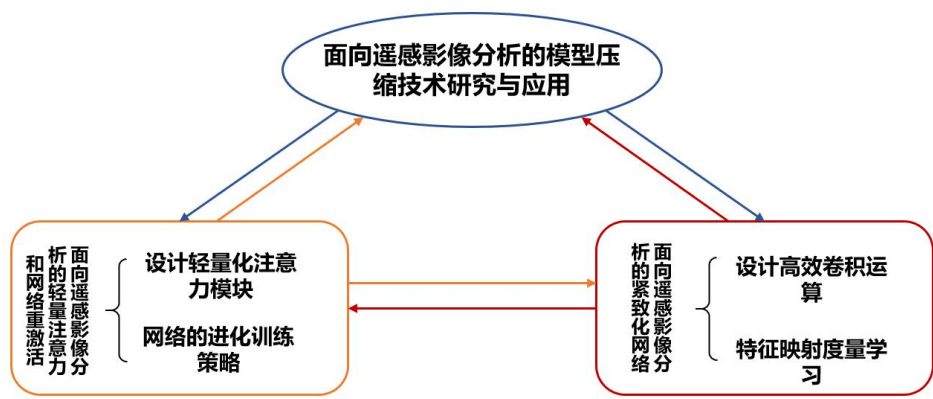


图 1 研究内容

(1) 面向遥感影像分析的轻量注意力和网络重激活

目前的基于注意力的卷积神经网络虽然在遥感影像分析任务中效果出众，但随着网络层数的加深，其计算量大、内存占用高等问题也更加显著，此外，目前的注意力

策略只关注单一样本本身，忽略了训练集样本的全局相关性。同时，深层网络必然给模型带来更多的参数冗余，因此，将张量分解、知识蒸馏等模型压缩思想应用在基于注意力的网络模型中可以有效降低注意力模块的计算复杂度和内存开销，同时可以大大减少网络的冗余度，提高网络的泛化性。据此，本项目拟开展以下研究工作：

- **轻量化注意力模块。**针对深层网络中注意力模块计算量过大、内存占用过高、全局相关性信息的丢失等问题，探索注意力模块中如何对特征图关键特征分布建模，产生注意力分数，阐明其本质并改进注意力生成策略，能够以极低的内存占用和极小的计算量对训练集中全局样本的本质特征建模，从而形成高效的注意力模块，显著提高网络对已有特征的增强能力。

- **网络的进化训练策略。**针对深层网络中参数冗余度过大的问题，分析其冗余卷积核的来源，并基于现有的知识蒸馏、相互学习等模型压缩算法思考如何对无效卷积核进行重激活，探索不同激活方法对无效卷积核重激活后的影响，从而实现无参数、无推理代价的网络进化训练策略，能够最大化利用已有模型参数，显著提高网络的泛化能力。

(2) 面向遥感影像分析的紧致化网络

当前，主流的深度网络模型在处理遥感图像分割和变化检测任务时主要存在以下问题：首先，由于高分辨率遥感影像的特征复杂性，使用深层网络模型进行特征编码是必然结果，这导致了模型计算量大、内存占用过高的问题；其次，影响网络性能的关键因素之一是如何更好地寻找对于给定数据的高维非线性语义空间，从而捕获数据全局信息来提高网络的特征表达。针对以上问题，本项目拟开展以下研究工作：

- **高效卷积运算。**针对深度网络模型参数多，内存需求大的问题，探索在通道维度的卷积核压缩算法在降低参数量中的作用；分析在通道维度简化卷积运算的过程中如何对冗余的特征图进行特征增强，从而在保证网络性能的前提下，有效降低网络对硬件的开销，实现面向遥感影像分析的紧致网络模型。

- **特征映射度量学习。**针对深度网络模型通过大量卷积和池化等高运量算、高内存占用的操作对单一样本进行特征编码，导致对高位语义空间映射开销过大，并且忽略了样本全局信息的问题，探索不同学习方法之间的关联及其对映射到的特征映射语义空间优劣的影响，研究新的基于特征映射度量的学习方法，从而在无任何参数的情况下，有效捕获样本全局信息，显著提高网络的特征表达。

1.2 研究目标

(1) 发展资源受限下的遥感图像分析方法

针对当前遥感图像语义分割和变化检测模型中注意力模块对计算和内存资源需求较高的问题，本课题拟研究注意力模块中对特征图关键特征分布建模机理，阐明其注意力分数本质，能够改进注意力图生成方法，在解决计算和内存资源需求较高问题的同时，改善目前注意力机制忽略全局样本相关性的缺陷，实现计算效率、内存需求及分割精度的有效平衡，发展资源受限下的轻量化注意力模块。

(2) 研究网络训练重激活进化策略减少参数冗余

针对目前用于遥感影像分析的深度网络层数过深、结构复杂导致的参数冗余量过大的问题，本课题拟研究网络参数冗余的量化表示，通过引入外部信息重新激活无效卷积核，达到在训练迭代的过程中对网络参数的充分利用，达到网络不断进化的效果，在一定程度上减少深度网络参数的冗余，显著提高网络的特征表达能力。

(3) 设计面向遥感影像分析高效紧凑的深度网络模型

针对目前面向遥感影像分析的深度网络深层特征数量巨大，导致卷积算子在深层语义特征编码时计算和内存开销巨大的问题，本课题拟研究卷积算子空间和通道相关性，利用现有卷积核空间通道压缩技术，简化设计轻量化卷积算子，集成无参数的特征增强和特征映射度量学习，形成一种新颖的紧凑网络模型，在保证遥感影像语义分割和变化检测精度的同时压缩模型大小并减少计算开销。

1.3 拟解决的关键科学问题

(1) 深度网络模型的信息去冗余

当前的科学研究表明，计算机视觉下游任务依赖于大规模数据集预训练模型，不同预训练模型迁移结果与优化策略的选择共同导致了模型泛化能力差，同时存在大量冗余。目前的模型压缩方法在降低网络冗余度的同时又损失了一定的模型表达能力。通过探索模型可学习参数即知识的冗余度量表示，优化当前训练策略以充分利用网络模型参数，降低冗余度。

(2) 视觉深度网络模型的效率与精度平衡

在数据“大爆炸”时代，人们对计算和内存资源的需求越来越高，因此在遥感影像分析任务中研究模型压缩方法的应用具有重要意义。当前的网络模型主要通过增加网络深度和宽度、更改特征融合方式、设计新的损失函数以提升分割精度，然而提升精度的同时会导致网络参数量增加、泛化性能降低等问题。通过探索模型参数量、计算效率与分割精度之间的关联，建立深度网络模型的效率与精度平衡准则。

2. 拟采取的研究方案（包括研究方法、技术路线）；

2.1 研究方法

首先，完善测试算法所需要的数据。已有的实验数据包括常用的自然图像大规模公开语义分割数据集 VOC2012、MSCOCO、CityScapes 等，高分辨率遥感影像语义分割数据集 ISPRS Vaihingen、ISPRS Potsdam、LoveDA、UOS2 等，以及高分辨率遥感影像变化检测数据集 WHU-Building、xView2、OSCD、LEVIR-CD 等。

其次，构建新的轻量化遥感影像分析模型。联合知识驱动与数据驱动各自的优势，分析数据、模型及参数学习算法之间的关联，研究遥感影像分析模型中效率与精度的平衡问题，发展模型压缩理论在遥感影像分析中的应用。

最后，算法仿真。针对提出的深度网络模型，利用 Python 和 Matlab 对算法进行仿真实现，建立完整代码工具箱及软件开发包，并对比不同方法的最终精度。

2.2 技术路线

具体技术路线如图 2 所示。

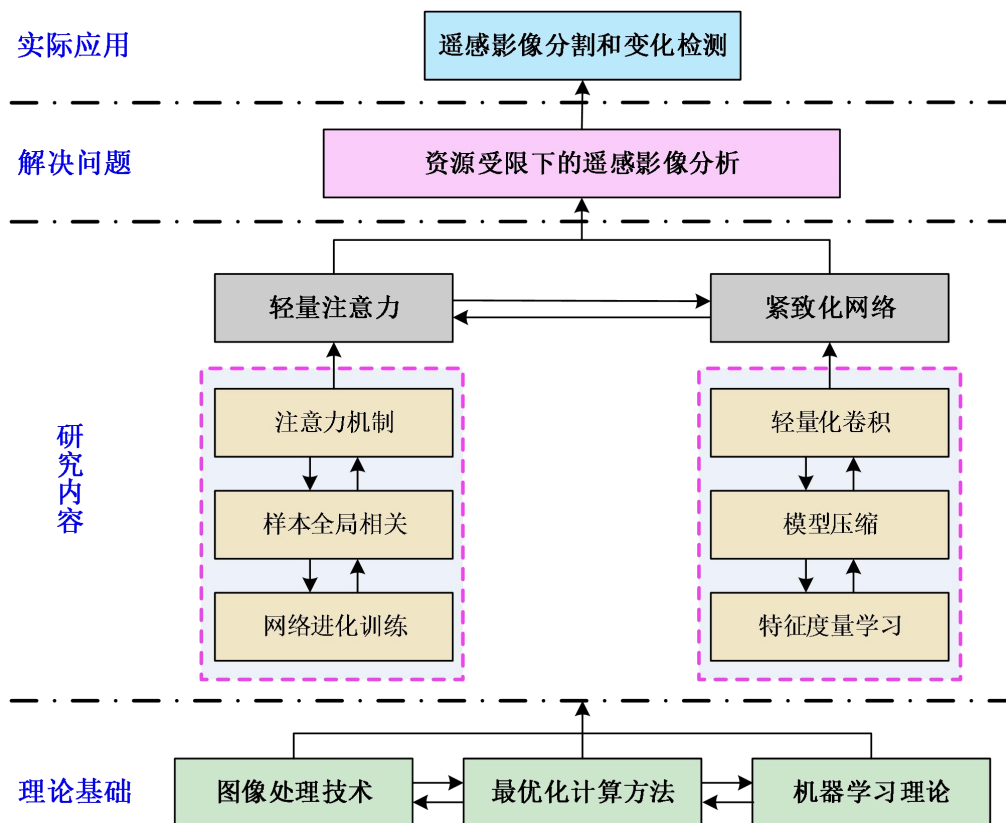


图 2 研究方案

陕西科技大学

硕士研究生学位论文开题报告



论 文 题 目 面向遥感影像分析的模型压缩技术
研究与应用

学 生 姓 名 耿信哲

学 科 专 业 电子信息

学 号 201612094

导 师 姓 名 雷涛

所 在 学 院 电子信息与人工智能学院

答 辩 日 期 2021 年 11 月 17 日

2021 年 11 月 17 日

一、选题依据（论文选题的背景、目的、意义、国内外研究现状分析等）

1. 选题背景

我国地处东亚，地大物博，覆盖多种地形地貌，如何对土地、森林、湿地等环境进行高效的监测和管理，实时监测其种类和数量等信息，为我国自然环境的保护提供可靠的数据则显得尤为重要。遥感对地观测技术是一种快速、高效的数据获取方法，其具有包含信息量大、信息覆盖面广、信息获取快速可靠、更新周期短、节省人力物力财力等诸多优势，现已成为对我国乃至世界自然环境研究的有利信息获取手段。在对遥感影像进行信息获取与分析中，对高分辨率遥感影像中地物进行变化检测检测和目标分类是必不可少的一个环节。

在过去，大数据与人工智能等技术还未广泛利用，对于遥感影像的语义分析停留在传统图像处理技术上，但传统算法性能较低，准确率不高，并且随着人类航空航天技术的不断发展，获取高分辨率遥感影像数据已经变得较为容易，传统的图像分割算法在有些问题上已经不再适用。于是，基于深度学习方法的遥感影像地物变化检测和分类在对遥感影像的分析与处理中更是受到越来越多的关注。但众所周知，随着遥感影像分析任务的数据复杂度越来越高，网络模型也变得越来越深，模型大小随之急剧增大，而模型大小和计算复杂度决定了模型能否更好地工业化部署。在此背景下，如何在资源限制的条件下保证模型的特征表达能力成为了学术和工业界共同要面对的难题。

2. 目的及意义

深度神经网络依靠更深的结构，更好地从大量数据中学习高级特征，这种强大的表达能力有别于传统的手工提取方式，能够在遥感图像分析应用中实现令人印象深刻的突破，包括图像分割、变化检测等。如今，深度神经网络已经成为学术界和工业界人工智能任务的支柱。然而，限制深度神经网络在物联网和边缘设备中用于实时、快速推理的主要因素是有限的计算能力、存储容量。在算法方面，近年来提出了各种模型压缩的技术，可分为四类：紧致化设计^[1]、张量分解^[2]、数据量化^[3]、网络稀疏化^[4]、知识蒸馏^[5]。具体来说，紧致化设计旨在设计更小的基本模型，同时仍能达到可接受的应用精度。张量分解将冗余的参数分解成一系列更小的矩阵或张量，以缩小内存体积和运算次数。数据量化或网络稀疏化分别减少了压缩原始模型的数位或连接。但是，这些方法在应用场景、压缩率、模型精度和硬件可用性方面需要做不同的权衡。同时，对于面向遥感影像分析的深度神经网络来说，其数据的高度复杂性决定了网络需要强大的特征表达能力，目前的模型压缩方法在遥感影像分析的任务中存在一定的局限性。因此现有的模型压缩方法在遥感影像分析任务中更好地应用有很大的工业和学术价值。

3. 国内外研究现状

在遥感影响分析任务中，国内外科研工作者做了大量的工作，但相关方法在场景分类和变化检测中的表现并不尽如人意，于是如何提高网络的泛化性能和特征表达为当前遥感影像智能分析的研究趋势之一。同时，在保证网络的性能前提下，如何平衡网络的计算和内存开销也是目前模型压缩领域的主要工作。

(1) 紧致化设计

自从 AlexNet^[6]在图像分类任务上取得重大突破以来，卷积神经网络经历了很多架构和模型，取得了越来越好的准确率。然而，性能的提高主要是由参数和操作增加的更深更宽的网络驱动的，这通常会降低它们的执行速度并增大内存开销，从而推动了紧致化模型的设计。紧致化设计旨在简化卷积这一基本操作来减少开销同时尽可能保持精度。在空间维度上，通常直观地可以将较大感受野的卷积核分解为较小的卷积核的叠加，在此基础上，衍生出了更多简单且有效的改进。非对称卷积^[7]的提出使参数和计算量急剧减少，且实验证明其在特定大小的特征图上的有效性；空洞卷积^[8]使用有限的参数和计算使原始卷积具有任意大小的感受野；可变形卷积^[9]可以看作空洞卷积的一般形式，它通过学习卷积偏置从而使卷积在固定参数和计算量情况下具有更大的灵活性。在通道维度上，更多的工作集中在对通道聚合拓扑的研究。在网络瓶颈层^[10]的提出后，越来越多的网络使用小尺寸卷积核进行维度变换，在进行大尺寸卷积核完成空间和通道间的相关性聚合，最后使用小尺寸卷积核恢复维度；分组卷积^[11]通过对输入通道分组，分别对组内进行常规卷积，有效地减少了深层特征空间通道过多带来的参数冗余；深度可分离卷积^[12]可以看作是分组卷积的极端形式，先进行逐通道卷积，再对生成特征图使用小尺寸卷积核进行通道维度信息融合，极大减少参数冗余的同时有限地保证了通道间信息的聚合。

(2) 张量分解

张量运算是神经网络的基本计算。因此，张量压缩是压缩和加速神经网络模型的一种很有效的方法，常用的方法包括对现有张量低秩分解和其他分解方式。通常对张量进行满秩分解可以显著降低空间复杂度，对于任意矩阵也可以使用奇异值分解找到其最佳低秩近似。一些工作^[2]使用奇异值分解代替原始权重矩阵，降低了其空间复杂度。此外，奇异值分解还可以用来压缩输入数据，以简化和加速迂回的训练^{[13][14]}。

(3) 数据量化

数据量化旨在减少流经神经网络模型的数据的位宽，因此可以缩小模型大小以节省内存，并简化计算加速操作。量化的操作主要涉及权重、激活值、梯度等

对象。朴素的量化方法直观地将数据投影到最近的离散级别，其中最典型的工作为二值量化^[3]，即使用裁剪函数将数据映射到 ± 1 ，使用极端的方法将模型大小和计算量减少到极低的水平。与启发式量化方法不同，更多的工作将量化表述为优化问题，并试图解决或近似解决这一问题。二值化等极低位宽的量化方法无法保证产生可接受的精度，特别是对于要求强大表达能力的大型模型。例如，XNOR网络^[15]具有二进制的权重和激活值，与 AlexNet 相比在 ImageNet 上的精度损失高达 12.4%。因此，在下游图像分析任务中需要更好的数据量化方法来近似表示原始数据。

(4) 网络稀疏化

与量化时减少操作数值位宽不同，网络稀疏化试图减少操作的数量。虽然它不能像量化那样简化算法本身，但它能够减少内存访问和计算操作的数量，从而获得加速。在单向压缩中，稀疏化方法通常可以获得比量化方法更高的精度，但是寻址非零元素的额外索引开销和不规则的执行模式成为主要缺点。此外，大多数工作需要在网络剪枝后重新训练以恢复模型精度。朴素的网络稀疏化方法是基于对不重要元素的启发式搜索。深度压缩^[16]使用一种简单的方法来消除绝对大小较小的权重，基于预训练模型，迭代消融和微调逐渐稀疏网络。研究人员证明，在相同内存占用的情况下，通过类似的剪枝方法修剪过的大型稀疏模型的精度始终高于其小型密集模型^{[17][18]}和从头开始训练的稀疏模型^[19]。修剪后的权重可以在随后的训练中冻结，也可以在其梯度显著增加时恢复，这些非结构化剪枝方法会导致额外的索引开销，如果没有对稀疏计算的强大支持，很难获得实际加速^[20]。因此，目前工业界更常用的剪枝方法是结构化剪枝，并且采用优化方法对网络进行稀疏化剪枝。近期的工作^[21]通过两步算法解决了该优化问题，通过 L1 范数 LASSO 回归迭代固定权重以解决稀疏化掩码，并通过最小二乘重建固定稀疏化掩码以更新权重。

(5) 知识蒸馏

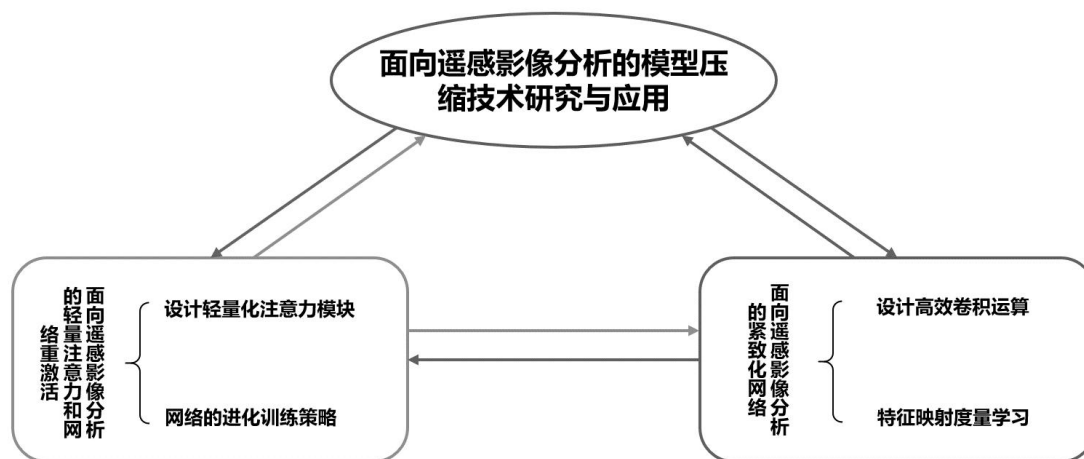
知识蒸馏是一种在繁琐的教师模型中提炼知识并将其压缩为单个紧凑学生模型的方法，以便可以将其部署到实际应用中。其中，教师网络产生的输出被用作训练学生网络的“软目标”。通过应用此方法，作者在 MNIST 数据集上取得了令人惊讶的结果，并表明通过将模型集成中的知识提取到单个模型中可以获得显著的改进。也有工作^[22]指出更深的网络有利于特征重用，学习更加抽象的特征表达。利用教师网络的中间层知识去训练一个窄而深的学生网络，从而达到模型压缩的目的。当教师网络与学生网络的模型大小差距过大时，知识蒸馏可能会导致学生网络性能下降^[23]。作者表明由于教师网络性能过强，导致学生没有足够能力

去模仿教师的行为，另一方面由于教师网络预测过于精准，导致标签不够"软"，这将削弱知识蒸馏的效果。因此有工作^[23]提出用教师助理来弥补教师和学生之间的差距，首先蒸馏教师网络知识到教师助理网络，然后再将教师助理网络的知识蒸馏到学生网络。传统知识蒸馏是将预训练好的教师网络知识传递学生网络，论文^[24]提出一种学生和教师网络相互学习的策略，在相互学习中，从一组未经训练的学生网络开始，它们同时学习以共同解决任务。

二、研究内容及拟解决的关键问题

1. 研究内容

本项目重点涉及两个方面的研究内容：面向高分辨率遥感影像分析的模型压缩算法和轻量化注意力模型，通过对主流的模型压缩算法在遥感影像分析任务应用的研究，重点解决卷积神经网络中注意力模块计算量大和内存消耗大、模型参数冗余度高的问题；通过设计轻量型卷积算子和改进训练方法，重点解决资源受限下的遥感影像的语义分割和变化检测精度。各研究内容之间的关系如图 2-1 所示。



示。

图 2-1 研究内容

(1) 面向遥感影像分析的轻量注意力和网络重激活

目前的基于注意力的卷积神经网络虽然在遥感影像分析任务中效果出众，但随着网络层数的加深，其计算量大、内存占用高等问题也更加显著，此外，目前的注意力策略只关注单一样本本身，忽略了训练集样本的全局相关性。同时，深层网络必然给模型带来更多的参数冗余，因此，将网络剪枝、知识蒸馏等模型压缩思想应用在基于注意力的网络模型中可以有效降低注意力模块的计算复杂度和内存开销，同时可以大大减少网络的冗余度，提高网络的泛化性。据此，本课题拟开展以下研究工作：

设计轻量化注意力模块。针对深层网络中注意力模块计算量过大、内存占用过高、全局相关性信息的丢失等问题，探索注意力模块中如何对特征图关键特征分布建模，产生注意力分数，阐明其本质并改进注意力生成策略，能够以极低的内存占用和极小的计算量对训练集中全局样本的本质特征建模，从而形成高效的注意力模块，显著提高网络对已有特征的增强能力。

网络的进化训练策略。针对深层网络中参数冗余度过大的问题，分析其冗余

卷积核的来源，并基于现有的知识蒸馏、相互学习等模型压缩算法思考如何对无效卷积核进行重激活，探索不同激活方法对无效卷积核重激活后的影响，从而实现无参数、无推理代价的网络进化训练策略，能够最大化利用已有模型参数，显著提高网络的泛化能力。

（2）面向遥感影像分析的紧致化网络

当前，主流的深度网络模型在处理遥感图像分割和变化检测任务时主要存在以下问题：首先，由于高分辨率遥感影像的特征复杂性，使用深层网络模型进行特征编码是必然结果，这导致了模型计算量大、内存占用过高的问题；其次，影响网络性能的关键因素之一是如何更好地寻找对于给定数据的高维非线性语义空间，从而捕获数据全局信息来提高网络的特征表达。针对以上问题，本项目拟开展以下研究工作：

设计高效卷积运算。针对深度网络模型参数多，内存需求大的问题，探索在通道维度的卷积核压缩算法在降低参数量中的作用；分析在通道维度简化卷积运算的过程中如何对冗余的特征图进行特征增强，从而在保证网络性能的前提下，有效降低网络对硬件的开销，实现面向遥感影像分析的紧致网络模型。

特征映射度量学习。针对深度网络模型通过大量卷积和池化等高运算量、高内存占用的操作对单一样本进行特征编码，导致对高位语义空间映射开销过大，并且忽略了样本全局信息的问题，探索不同学习方法之间的关联及其对映射到的特征映射语义空间优劣的影响，研究新的基于特征映射度量的学习方法，从而在无任何参数的情况下，有效捕获样本全局信息，显著提高网络的特征表达。

2. 研究目标

（1）发展面向遥感影像分析的轻量化注意力模块

针对当前遥感图像语义分割和变化检测模型中注意力模块对计算和内存资源需求较高的问题，本课题拟研究注意力模块中对特征图关键特征分布建模机理，阐明其注意力分数本质，能够改进注意力图生成方法，在解决计算和内存资源需求较高问题的同时，改善目前注意力机制忽略全局样本相关性的缺陷，实现计算效率、内存需求及分割精度的有效平衡，发展资源受限下的轻量化注意力模块。

（2）研究网络训练重激活进化策略减少参数冗余

针对目前用于遥感影像分析的深度网络层数过深、结构复杂导致的参数冗余量过大的问题，本课题拟研究网络参数冗余的量化表示，通过引入外部信息重新

激活无效卷积核，达到在训练迭代的过程中对网络参数的充分利用，达到网络不断进化的效果，在一定程度上减少深度网络参数的冗余，显著提高网络的特征表达能力。

（3）设计面向遥感影像分析高效紧凑的深度网络模型

针对目前面向遥感影像分析的深度网络深层特征数量巨大，导致卷积算子在深层语义特征编码时计算和内存开销巨大的问题，本课题拟研究卷积算子空间和通道相关性，利用现有卷积核空间通道压缩技术，简化设计轻量化卷积算子，集成无参数的特征增强和特征映射度量学习，形成一种新颖的紧凑网络模型，在保证遥感影像语义分割和变化检测精度的同时压缩模型大小并减少计算开销。

3. 拟解决的关键问题

在本课题研究工作中，拟解决的关键问题有以下三个：

问题一：高分辨率遥感影像语义分割任务依赖于大规模数据集预训练模型，不同预训练模型迁移结果与优化策略的选择共同导致了模型泛化能力差，同时存在大量冗余。

问题二：目前的基于注意力模块的神经网络存在无法获取训练样本间本质关系的缺陷，并且深层特征注意力内存和计算开销巨大。

问题三：主流面向遥感影像变化检测任务的方法均使用深层编解码网络，网络层数的不断增加导致模型在训练和推理过程中需要大量的计算和存储，十分不利于工业部署。

三、研究方案及可行性分析（研究思路与方法、技术路线、实验或调查方案及可行性分析，从事自然科学研究所需主要仪器设备和试剂，从事人文社科类研究所需要的工作条件）

1. 研究思路与方法

本课题首先进行数据收集，完善测试方法所需数据。其次对现有的面向遥感影像分析的深度神经网络以及现有的模型压缩方法进行研究，对现有模型压缩思想做出进一步思考，并将其应用到遥感影像分析任务中，从而设计面向遥感影像分析的轻量型模块和紧凑神经网络，并保证图像语义分割和变化检测精度。最后，经过计算机编码对所设计方法进行代码实现，并通过不断实验迭代得到最终结果。

本课题主要研究方法包括以下几种：

- (1) 文献调查法：查阅大量与课题相关国内外文献，了解所研究课题的发展动态及方向；
- (2) 理论研究法：分析已有深度卷积神经网络的优缺点，学习并研究主流模型压缩方法，将二者有机结合形成高效遥感影像分析解决方案；
- (3) 仿真研究法：利用计算机编码实验对算法进行初步设计和实现；
- (4) 实验对比法：通过对方法实现的结果进行对比，确定合适可行的方法。

2. 技术路线

首先，搜集并完善训练和测试提出方法的数据集，已有的实验数据包括常用的自然图像识别数据集 MNIST、CIFAR-10、ImageNet 等，自然图像语义分割数据集 CityScapes、VOC2012、MS COCO 等，遥感影像地物分类数据集 ISPRS Vahingen、ISPRS Potsdam、LoveDA、UOS 等，遥感影像变化监测数据集 CDD、LEVIR-CD、OSCD 等。在此基础上，继续扩大训练及测试数据集，以充分验证提出方法的鲁棒性。

其次，根据现有模型压缩中紧凑结构设计、网络剪枝、知识蒸馏等方法，分析数据与模型参数之间的关联，研究遥感影像分析模型的效率与精度平衡问题，提出面向高分辨率遥感影像分析的轻量化注意力网络和紧致化网络，从而发展资源受限下的遥感影像分析方法。

再次，针对已提出的轻量化注意力网络和紧致化网络模型，利用 Python、PyTorch 等开发环境和框架进行算法仿真实现，根据实验结果对比已有的主流遥感影像地物分类和变化检测方法，展示已提出的网络模型的优越性，完善并建立遥感影像分析项目软件开发包和代码仓库。

最后，将本次课题提出的模型应用到现实中的遥感影像地物分类及变化检测

实际任务中，实现实时轻量化遥感影像分析系统。

具体技术路线如图 3-1 所示。

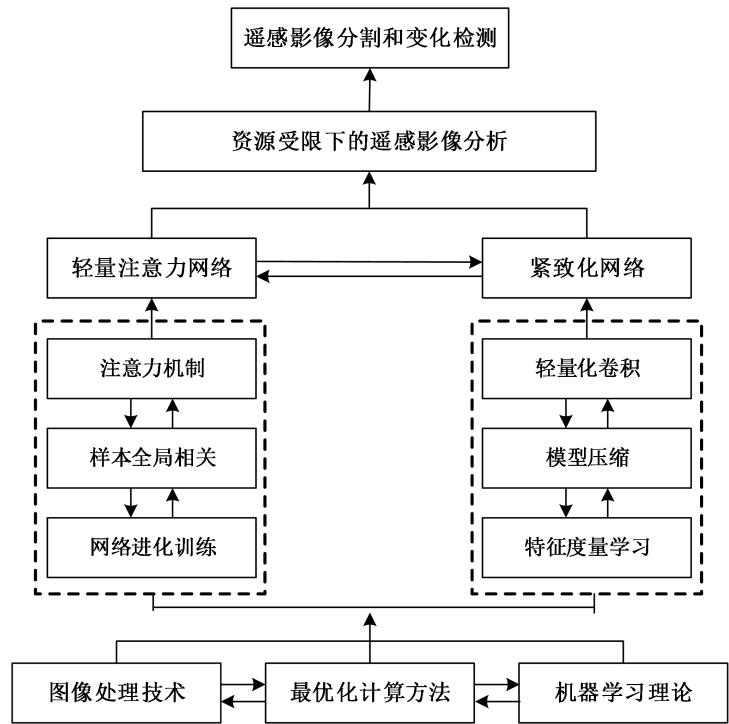


图 3-1 技术路线

3. 实验及可行性分析

(1) 理论依据

本课题的理论依据是数字图像处理理论和深度学习理论。

数字图像处理是对图像进行分析、加工、和处理，使其满足视觉、心理以及其他要求的技术。其研究源于两个主要的应用领域：

一是为了便于人们分析而对图像信息进行改进，提高图像的视感质量，如进行图像的亮度、彩色变换，增强、抑制某些成分，对图像进行几何变换等，以改善图像的质量。

二是为使机器自动理解而对图像数据进行存储、传输及显示，提取图像中所包含的某些特征或特殊信息，这些被提取的特征或信息往往为计算机分析图像提供便利。提取特征或信息的过程是模式识别或计算机视觉的预处理。提取的特征可以包括很多方面，如频域特征、灰度或颜色特征、边界特征、区域特征、纹理特征、形状特征、拓扑特征和关系结构等。图像数据的变换、编码和压缩，以便于图像的存储和传输。

深度学习是人工智能领域中最能够体现智能的一个分支，深度学习是一门多领域交叉学科，涉及概率论、统计学、逼近论、凸分析等多门学科。卷积神经网络是一类包含卷积计算且具有深度结构的前馈神经网络，是深度学习的代表算法

之一。卷积神经网络具有表征学习能力，卷积神经网络目前在很多很多研究领域取得了巨大的成功，例如：语音识别、图像识别、图像分割、自然语言处理等。

(2) 技术依据

本课题技术依据包括：机器学习技术、图像分割技术。

机器学习是一门多领域交叉学科，涉及概率论、统计学、逼近论、凸分析、算法复杂度理论等多门学科。专门研究计算机怎样模拟或实现人类的学习行为，以获取新的知识或技能，重新组织已有的知识结构使之不断改善自身的性能。其中的深度学习是机器学习领域中一个新的研究方向，它被引入机器学习使其更接近于人工智能。深度学习是学习样本数据的内在规律和表示层次，这些学习过程中获得的信息对诸如文字，图像和声音等数据的解释有很大的帮助。它的最终目标是让机器能够像人一样具有分析学习能力，能够识别文字、图像和声音等数据。深度学习是一个复杂的机器学习算法，在语音和图像识别方面取得的效果，远远超过先前相关技术。

图像分割是指将图像分割成若干特定的、具有独特性质的区域并提取出感兴趣区域的技术过程，它是由图像处理到图像分析的关键步骤。图像分割提取出感兴趣区域对于后续的图像处理具有很大的帮助，降低了图像处理的难度。但是，目前自动分割算法会存在各种问题，例如，光照不均匀、噪声的影响、图像中存在不清晰的部分，以及阴影等。因此，人们希望引入一些人为的知识导向和人工智能的方法，用于纠正某些分割中的错误。目前，卷积神经网络可以很好的解决这些问题。对于遥感影像分析，图像分割技术可以充当非常实用且必要的角色，遥感影像语义分割需要将高分辨率遥感图像进行像素级别密集分类，通过对不同语义类别进行图像分割，从而达到对遥感图像中地物的语义理解。而遥感影像变化检测则基于对遥感图像的语义分割即像素级分类，将多个时相的遥感影像及差分图像进行叠加再根据变化类型进行分类，从而得到不同时相间地物目标变化，与传统的变化检测不同，该方法不用对每个遥感影像进行分类操作，不再依赖于对地表覆盖类型的分类精度。

4. 主要仪器设备

(1) 学校图书馆以及陕西科技大学网络图书馆数据库提供研究所需要的文献资料

(2) 深度学习工作站: Intel(R) Xeon(R) Gold 6226R CPU @ 2.90GHz, NVIDIA GeForce RTX 3090 24GB

(4) 所使用的软件工具: Ubuntu18.04, Python3.7, PyTorch1.7, OpenCV, TensorboardX, FinalShell

四、预期成果、创新之处、成果预期社会效益

1. 预期结果

(1) 本课题拟利用主流模型压缩方法，面向遥感影像分析的轻量型注意力和紧致化网络，实现高分辨率遥感分析的地物分类和变化检测，在获取资源信息和地理数据方面发挥重要作用。

(2) 发表 1-2 篇学术论文。

2. 创新点

本课题重点涉及两个方面的创新内容：

(1) 面向高分辨率遥感影像分析的模型压缩算法和轻量化注意力模型。通过对主流的模型压缩算法在遥感影像分析任务应用的研究，针对深层网络中参数冗余度过大的问题，分析其冗余卷积核的来源，并基于现有的知识蒸馏、相互学习等模型压缩算法思考如何对无效卷积核进行重激活，探索不同激活方法对无效卷积核重激活后的影响，从而实现无参数、无推理代价的网络进化训练策略，能够最大化利用已有模型参数，显著提高网络的泛化能力。针对当前遥感图像语义分割和变化检测模型中注意力模块对计算和内存资源需求较高的问题，本课题拟研究注意力模块中对特征图关键特征分布建模机理，阐明其注意力分数本质，能够改进注意力图生成方法，在解决计算和内存资源需求较高问题的同时，改善目前注意力机制忽略全局样本相关性的缺陷，实现计算效率、内存需求及分割精度的有效平衡，发展资源受限下的轻量化注意力模块。

(2) 面向高分辨率遥感影像分析的紧致化网络模型。针对深度网络模型参数多，内存需求大的问题，探索在通道维度的卷积核压缩算法在降低参数量中的作用，分析在通道维度简化卷积运算的过程中如何对冗余的特征图进行特征增强，从而在保证网络性能的前提下，有效降低网络对硬件的开销。实现面向遥感影像分析的紧致网络模型通过设计轻量型卷积算子和改进训练方法，重点解决资源受限下的遥感影像的语义分割和变化检测精度。

3. 预期社会效益

当前遥感形成了一个从地面到空中，乃至空间，从信息数据收集、处理到判读分析和应用，对全球进行探测和监测的多层次、多视角、多领域的观测体系，成为获取地球资源与环境信息的重要手段。为了提高对这样庞大数据的处理速度，遥感数字图像技术随之得以迅速发展。将遥感影像与人工智能技术相结合，所获得的社会效益是巨大的。在工程和学术方面本课题可以解决深度神经网络模型过大、计算量过高导致的工业部署困难的问题。

五、工作进度安排及经费预算

本课题计划在一年半内完成，分四个阶段实施：

1. 2021.09-2021.11

查找资料，学习遥感影像分析相关方法技术，制定研究方案；

2. 2021.12-2022.04

研究适用于遥感影像地物分类和变化检测的卷积神经网络，并研究主流模型压缩方法；

3. 2022.05-2022.11

针对现有卷积神经网络的缺陷，综合模型压缩主流方法，思考设计轻量化注意力模块和紧致化网络，并设计实验验证其有效性，进而反复验证修改；

4. 2022.12-2023.03

总结工作，撰写论文。

六、参考文献

- [1] Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv preprint arXiv:1704.04861, 2017.
- [2] Zhang X, Zou J, He K, et al. Accelerating very deep convolutional networks for classification and detection[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 38(10): 1943-1955.
- [3] Courbariaux M, Bengio Y, David J P. Binaryconnect: Training deep neural networks with binary weights during propagations[C]//Advances in neural information processing systems. 2015: 3123-3131.
- [4] Han S, Pool J, Tran J, et al. Learning both Weights and Connections for Efficient Neural Network[J]. Advances in Neural Information Processing Systems, 2015, 28.
- [5] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[J]. arXiv preprint arXiv:1503.02531, 2015.
- [6] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25: 1097-1105.
- [7] Szegedy C, Vanhoucke V, Ioffe S, et al. Rethinking the inception architecture for computer vision[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 2818-2826.
- [8] Chen L C, Barron J T, Papandreou G, et al. Semantic image segmentation with task-specific edge detection using cnns and a discriminatively trained domain transform[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 4545-4554.
- [9] Dai J, Qi H, Xiong Y, et al. Deformable convolutional networks[C]//Proceedings of the IEEE international conference on computer vision. 2017: 764-773.
- [10] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4700-4708.
- [11] Xie S, Girshick R, Dollár P, et al. Aggregated residual transformations for deep neural networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1492-1500.
- [12] Chollet F. Xception: Deep learning with depthwise separable convolutions [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1251-1258.
- [13] Kumamoto T, Suzuki M, Matsueda H. Singular-value-decomposition analysis of associative memory in a neural network[J]. Journal of the Physical Society of Japan, 2017, 86(2): 024005.
- [14] Xue S, Jiang H, Dai L, et al. Unsupervised speaker adaptation of deep neural network based on the combination of speaker codes and singular value decomposition for speech recognition[C]//2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2015: 4555-4559.
- [15] Rastegari M, Ordonez V, Redmon J, et al. Xnor-net: Imagenet classification using

- binary convolutional neural networks[C]//European conference on computer vision. Springer, Cham, 2016: 525-542.
- [16]Han S, Mao H, Dally W J. Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding[J]. arXiv preprint arXiv:1510.00149, 2015.
- [17]Zhu M, Gupta S. To prune, or not to prune: exploring the efficacy of pruning for model compression[J]. arXiv preprint arXiv:1710.01878, 2017.
- [18]Narang S, Elsen E, Diamos G, et al. Exploring sparsity in recurrent neural networks[J]. arXiv preprint arXiv:1704.05119, 2017.
- [19]Alford S, Robinett R, Milechin L, et al. Training behavior of sparse neural network topologies[C]//2019 IEEE High Performance Extreme Computing Conference (HPEC). IEEE, 2019: 1-6.
- [20]Wen W, Wu C, Wang Y, et al. Learning structured sparsity in deep neural networks[J]. Advances in neural information processing systems, 2016, 29: 2074-2082.
- [21]He Y, Zhang X, Sun J. Channel pruning for accelerating very deep neural networks[C]//Proceedings of the IEEE international conference on computer vision. 2017: 1389-1397.
- [22]Romero A, Ballas N, Kahou S E, et al. Fitnets: Hints for thin deep nets[J]. arXiv preprint arXiv:1412.6550, 2014.
- [23]Mirzadeh S I, Farajtabar M, Li A, et al. Improved knowledge distillation via teacher assistant[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2020, 34(04): 5191-5198.
- [24]Zhang Y, Xiang T, Hospedales T M, et al. Deep mutual learning[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 4320-4328.